

激活稀疏并不独立提升神经元单义性： 一个被网络深度解释掉的表观效应

柯宇峰 (Yufeng Ke)

独立研究者

UTF-8@msn.com

2026 年 5 月

说明：本文为中文阅读版，供交流理解之用。正式版本为英文，已发布于 Zenodo: <https://doi.org/10.5281/zenodo.20465262>。两版内容一致；如有出入，以英文版为准。

摘要

激活稀疏被广泛用于加速大语言模型推理，并常被认为能让神经元更可解释、更“单义”。我们直接检验这一说法：比较一个效率驱动的 ReLU 稀疏模型 (MiniCPM-S-1B) 与其稠密的 SiLU 兄弟模型 (MiniCPM-1B) 在逐层神经元单义性上的差异，用两把尺子测量——基于 Jensen-Shannon 距离的概念可分性分数，以及基于方差的 η^2 分数。虽然稀疏模型在更深层显得更单义，我们证明这一优势完全由网络深度解释：在回归掉深度之后，逐层稀疏度与单义增益之间不存在可检测的相关（残差 $r \approx 0.12$ ）。该阴性结果在两个正交的概念维度（主题、情感）和两把方法上不同的尺子下都稳健。我们的发现与“在混合专家 (MoE) 模型中稀疏会诱导单义性”的报告存在张力，提示稀疏与单义性之间的任何联系，可能取决于稀疏的具体形式，而非普遍成立。

1 引言

激活稀疏——指任意输入下只有一小部分神经元被激活——已成为给大模型省电、提速的热门途径。这条研究线上反复出现一个说法：这种稀疏还会让单个神经元更可解释、更“单义”。然而这个说法很少被直接检验：据我们所知，没有前人测量过——一个为效率而生的、原生稀疏的模型，它的神经元是否真的比稠密版更单义。我们提供了这样一个检验，在固定概念集下比较一个 ReLU 稀疏模型与其稠密兄弟。关键在于，我们控制了一个结果证明是主导性的混淆变量——网络深度。稀疏模型表面上确实显得更单义，但我们发现这个表观优势**完全由深度解释**：一旦回归掉深度，稀疏就不再带来任何可检测的独立效应——这个阴性结果在两个正交的概念维度、两把不同的单义性尺子下都成立。

为检验该说法，我们研究一对仅激活函数不同的受控模型：MiniCPM-S-1B（ReLU 稀疏）和它稠密的 SiLU 兄弟 MiniCPM-1B。用两把互补的单义性尺子——JS 概念可分性分数和 η^2 （类别解释方差占比）分数——我们在两个概念集（新闻主题、情感）上测量两个模型的逐层神经元单义性。然后追问：稀疏对单义性的贡献，是否**超出**单靠网络深度所能解释的范围。本文贡献如下：

- 我们提供了（据我们所知）首个”效率驱动的原生稀疏模型 vs 稠密版”逐层神经元单义性的直接比较，并引入了一套深度受控的方法学，用以将稀疏的效应与深度引起的效应分离开来——我们主张，这一控制应当成为该研究线上的标准做法。
- 我们表明，稀疏模型表观上的单义优势完全由网络深度解释：回归掉深度后，稀疏没有可检测的独立效应（残差相关 $r \approx 0.12$, $p \approx 0.42$ ）。
- 我们证明该阴性结果稳健，在两个正交概念维度、两把方法上不同的尺子下都成立。
- 我们讨论为什么本发现与 MoE 模型中”稀疏诱导单义”的报告存在张力，提示该效应可能依赖稀疏的具体形式。

2 相关工作

为效率而生的激活稀疏。一类工作利用”ReLU 类激活在任意输入下让多数神经元不活跃”这一观察，实现更快更省的推理。这类文献主要关心效率—性能权衡，触及可解释性时也是非正式的——断言而非测量稀疏带来的单义收益。我们取其中一个非正式说法，直接检验。

度量单义性。一类不断增长的可解释性工作量化单个单元有多单义，常借助稀疏自编码器（SAE）和自动”解释—打分”流程。近期工作直接比较 SAE 与其底座模型的单义性，引入了我们所采用的那类概念可分性分数。关键在于：在这类文献里，”稀疏”对象是一个外部训练、专为可解释性优化的 SAE——所以发现它更可解释，部分是定义使然。我们的对象不同：一个仅为效率训练、从未为可解释性优化的模型的原生激活稀疏。这使得”它是否顺带更单义”成为一个真正开放、不循环的问题。

MoE 中的稀疏与单义性。与本文最直接相关的近期工作报告：在 MoE 模型中，专家神经元比稠密 FFN 神经元更不多义，且随路由变稀疏而差距扩大——这是”稀疏 $\rightarrow$ 单义”联系的证据。我们的研究在稀疏形式上不同（激活而非路由），并在该设定下得出相反结论，这促使我们提出”该效应依赖稀疏形式”的看法。

跨深度的表征。最后，”表征性质随网络深度变化、且激活稀疏本身逐层不同（首末层表现独特）”是已确立的事实。这部分工作是我们所控制的混淆变量的依据，也指导了我们对所观察到的分层增益的解读。

3 方法

3.1 模型。我们比较同一家族中仅 MLP 激活函数不同的两个模型。稀疏模型是 MiniCPM-S-1B-sft (llama 格式)，其原激活被替换为 ReLU 并经 ProSparse 进一步稀疏化，获得高激活稀疏度。稠密基线是其兄弟 MiniCPM-1B-sft，保留原始 SiLU 激活。两者架构 (52 层、MLP 中间维 3840)、参数规模 (约 1B)、训练血统相同；稀疏模型由稠密模型派生。这把“激活稀疏与否”隔离为唯一变量。

3.2 探测数据。沿正交维度使用两个带标签概念集。主题：从 AG News 取四类 (世界、体育、财经、科技)。情感：从 SST-2 取两类 (正、负)。每个概念集每类取固定数量句子，分别喂入两个模型。

3.3 逐神经元激活采集。对每个模型，在每一层的激活后输出 (mlp.act_fn) 注册前向钩子。对一条输入句子，记录每个神经元的峰值激活 (在所有 token 位置取最大)。由此对每一层每个神经元，得到一组按概念标签分组的激活值。

3.4 单义性度量。用两把方法上不同的尺子，逐神经元计算、按层平均。(1) *JS* 概念可分性：对每个神经元，按概念类别构造分箱激活分布，计算类间两两 *JS* 距离的均值；值越高，神经元激活越能区分概念。(2) η^2 (类别解释的方差占比)：对每个神经元，计算其总激活方差中由类间均值解释的比例 (单因素方差分析 η^2)；值越高，激活越受概念身份支配。两把尺子以不同方式刻画单义性——分布差异 vs 方差分解——故二者一致可防”某把尺子的人为产物”。

3.5 控制深度。定义每层”增益”为稀疏模型层得分减稠密模型层得分。由于表征性质已知随深度变化，我们将层号视为潜在混淆变量。将增益拟合为层号的三次多项式，取残差——增益中不被深度解释的部分。再检验逐层稀疏度 (沉默神经元比例) 是否与该残差相关；接近零的相关说明稀疏在深度之外对单义性无贡献。

4 结果

4.1 表面上的微小优势。在代表性中间层 (第 26 层)，稀疏模型的 *JS* 概念可分性分数略高于稠密模型 (0.3624 vs 0.3489，增益 +0.0135)。单看这个微小正增益，与”稀疏提升单义性”一致——但如下所示，它经不起推敲。

4.2 增益是分层的，并非均匀。扫描全部 52 层发现，增益并非恒定：浅层略负，深层稳定为正。该模式稳定——在三次对探测数据的随机抽样 (每类 100 句) 下，每层增益的符号都保持不变。

4.3 增益跟随深度，而非稀疏度。一个自然假设是增益反映每层有多稀疏。我们发现并非如此：跨层来看，逐层稀疏度与增益相关可忽略 (Pearson $r = 0.105$, $p = 0.46$)。相反，层深与增益强相关 (Pearson $r = 0.738$, Spearman 0.776)。表观的稀疏优势，对齐的是深度，而非稀疏程度。

4.4 控制深度后稀疏无独立效应 (核心结果)。为分离任何稀疏特有的贡献，我们将增益对层深回归 (三次拟合；深度解释了增益方差的 $R^2 = 0.721$)，检查残差。逐层稀疏度与该残差无

可检测相关 (Pearson $r = 0.116$, $p = 0.415$; Spearman 0.069)。换言之，一旦计入深度，稀疏对单义性无任何可测量的贡献。这是我们的核心结果。

4.5 稳健性：第二个概念维度。用情感 (SST-2) 而非主题重复分析，稀疏度与增益的表面相关实际上更大、更诱人 ($r = 0.352$)。但回归掉深度后，它再次消失 (残差 $r = 0.020$, $p = 0.889$)。阴性结果因此在第二个正交概念维度下也成立——而这个维度起初看起来对”稀疏假设”更有利。

4.6 稳健性：第二把尺子。把 JS 尺子换成方法上不同的 η^2 尺子，得到相同结论。 η^2 下深度对增益的解释更少 ($R^2 = 0.464$)，但核心发现不变：控制深度后，稀疏无独立效应 (残差 $r = -0.107$, $p = 0.452$)。两把不同尺子的一致表明，该阴性结果不是任何单一测量选择的产物。

4.7 一处残留的非单调性 (记录，不主张)。我们顺带指出，深度—增益曲线并非完全单调：中深层出现一个微弱”驼峰”，末层出现一个尖峰。后者与有充分文献记载的”末层”异常一致，我们不再解读；前者很微弱，留作未来工作。

5 讨论

5.1 解读。我们的结果提醒：不应把逐层单义性增益当作”稀疏本身提升可解释性”的证据。在我们的设定里，稀疏模型在更深层确实更单义——但这是与深度共现、而非与稀疏共现：两者恰好一起上升，一旦控制深度，稀疏信号就消失。这是教科书式的混淆。它提示：先前关于”稀疏提升可解释性”的非正式说法，若基于未控制的逐层比较，可能部分反映的是”更深的表征更易类别可分”这一已知倾向，而非稀疏本身的效应。

5.2 走向深度受控的稀疏-可解释性主张评估。我们的核心发现——一个表观的稀疏优势在深度控制下消失——其方法论含义超出本次具体比较。任何两个仅在某项架构属性上不同的模型之间的逐层比较，只要该属性与深度相关，就容易受到深度混淆产生的伪迹的影响。因此我们建议：未来任何主张稀疏 (或任何其他架构变体) 与单义性之间存在联系的工作，都应同时报告表面相关性以及在回归掉层深度之后的残差相关性。本文所用的三次拟合协议是一个最低限度的实例；随着相关文献的成熟，更精致的控制方式 (例如对多个混淆变量的偏相关、按层分层的分析等) 可能更为合适。我们希望本案例研究能够推动可解释性研究中对”控制混淆变量的测量”的更广泛采用。

5.3 与 MoE 发现的张力。我们的阴性结果与”在 MoE 模型中稀疏提升单义性、且随路由变稀疏而增强”的工作存在表面张力。我们不质疑那些发现；相反，这种反差提示：稀疏与单义性的关系，可能取决于稀疏的形式。MoE 路由稀疏 (在专门化的专家子网络间选择) 与激活稀疏 (在共享 FFN 内把单个神经元置零) 机制不同，可能以不同方式关联可解释性。究竟哪种稀疏形式 (如果有的话) 能因果性地提升单义性，是一个我们的结果有助于揭示的开放问题。

5.4 局限。几点局限框定了我们结论的范围。**第一，也是最重要的：我们的证据来自单一模型家族。**我们只比较了 MiniCPM-S / MiniCPM 这一对；曾尝试加入第二对 (ProSparse / ReLuLLaMA 对其稠密底座)，但受阻于这些稀疏模型的工程封装、以及免费可得硬件的显存上限。因此阴性结果能否跨模型家族推广，仍是开放问题，也是未来工作最重要的方向。**第二，我**

们只研究了单一模型规模（约 1B）和一个简化的、基于直方图的概念可分性度量实现；未与成熟的基于 SAE 的可解释性度量交叉验证。**第三，也最根本：**阴性结果报告的是”未检测到效应”，而非”证明效应不存在”；稀疏可能施加了一种过小、或我们的设置无法捕捉的影响。我们的主张相应地是狭窄的：在本设定内，激活稀疏除深度所解释的之外，不带来单义性收益。

5.5 未来工作。本研究是一项更大规划的第一步。我们正在进行的后续工作包括：（1）将分析扩展到第二组独立的稀疏-稠密模型对（如 ProSparse-LLaMA 与其稠密基座），以检验本文阴性结果的跨家族稳健性；（2）将概念可分性度量从直方图近似升级为基于稀疏自编码器的成熟度量，并做交叉验证；（3）在更大参数规模上重复本实验，以考察单义性-深度关系是否随规模变化。我们预期这些扩展将进一步厘清——在何种条件下、对何种形式的稀疏，可解释性收益才真正出现。

6 结论

我们检验了”激活稀疏让神经元更单义”这一常见说法，用一个 ReLU 稀疏模型与其稠密兄弟的受控比较。稀疏模型的表现优势完全由网络深度解释；一旦控制深度，稀疏无任何可检测的独立效应——这个阴性结果在两个概念维度、两把尺子下都稳健。我们希望这能推动对”稀疏的可解释性收益究竟在何时、对何种稀疏形式才真正出现”进行更审慎的、控制了混淆变量的测量。

参考文献

1. Li 等. The Lazy Neuron Phenomenon: On Emergence of Activation Sparsity in Transformers. arXiv:2210.06313, 2023.
2. Song 等. ProSparse: Introducing and Enhancing Intrinsic Activation Sparsity within Large Language Models. arXiv:2402.13516, 2025.
3. Luo 等. Sparsing Law: Towards Large Language Models with Greater Activation Sparsity. arXiv:2411.02335, 2025.
4. Bills 等. Language models can explain neurons in language models. OpenAI, 2023.
5. Fereidouni 等. Evaluating Sparse Autoencoders for Monosemantic Representation. Findings of EACL 2026.
6. Herbst 等. The Expert Strikes Back: Interpreting Mixture-of-Experts Language Models at Expert Level. arXiv:2604.02178, 2026.
7. Wild & Anderson. Uncovering Layer-Dependent Activation Sparsity Patterns in ReLU Transformers. arXiv:2407.07848, 2024.